


## Approssimazione secondo il criterio dei minimi quadrati (caso discreto)

Dati  $m + 1$  punti **distinti** (**punti di osservazione**)  $x_0, x_2, \dots, x_m \in [a, b]$  e  $m + 1$  valori (**osservazioni**)  $y_0, y_2, \dots, y_m \in \mathbb{R}$ , si vuole determinare il **modello matematico** che meglio approssima tale insieme di dati sperimentali

$$f(x; \alpha_0, \alpha_1, \dots, \alpha_n) = y$$

dove  $\alpha_0, \alpha_1, \dots, \alpha_n$  sono gli  $n + 1$  **parametri** da determinare, con  $m > n$ .

Si vogliono determinare i parametri **incogniti**  $\alpha_0, \alpha_1, \dots, \alpha_n$  (detti **gradi di libertà**) in modo tale che la **distanza** tra  $f(x; \alpha_0, \alpha_1, \dots, \alpha_n)$  e i dati osservati **sia minima**, ossia più piccola possibile. Occorre poi verificare la bontà del modello adottato.



## Approssimazione secondo il criterio dei minimi quadrati (caso discreto)

Se si considera il sistema di  $m + 1$  equazioni nelle  $n + 1$  incognite  $\alpha_0, \alpha_1, \dots, \alpha_n$ , si ottiene il **sistema sovradeterminato**  $m > n$

$$\begin{cases} f(x_1; \alpha_0, \alpha_1, \dots, \alpha_n) - y_1 = \varepsilon_0 \\ f(x_2; \alpha_0, \alpha_1, \dots, \alpha_n) - y_2 = \varepsilon_1 \\ \vdots \\ f(x_m; \alpha_0, \alpha_1, \dots, \alpha_n) - y_m = \varepsilon_m \end{cases}$$

dove  $\varepsilon_i, i = 0, \dots, m$ , è il disturbo (rumore) che “sporca” l’ $i$ -esimo dato  $y_i$ .

Si tratta di determinare  $\alpha_0, \alpha_1, \dots, \alpha_n$  in modo tale che  $\varepsilon_i, i = 0, \dots, m$ , siano più piccoli possibile.

Sia  $m \geq n$ : se si considera il principio dei minimi quadrati, si determinano  $\alpha_0, \alpha_1, \dots, \alpha_n$  in modo che il vettore  $\varepsilon = (\varepsilon_0, \dots, \varepsilon_m)^T \in \mathbb{R}^{m+1}$  abbia norma euclidea minima (cioè più piccola possibile), ossia in modo che sia minima la funzione  $Q(\alpha_0, \alpha_1, \dots, \alpha_n)$  detta somma dei quadrati dei residui:

$$Q(\alpha_0, \alpha_1, \dots, \alpha_n) = \sum_{i=0}^m \varepsilon_i^2 = \sum_{i=0}^m \left( f(x_i; \alpha_0, \alpha_1, \dots, \alpha_n) - y_i \right)^2$$

oppure

$$= \sum_{i=0}^m w_i \varepsilon_i^2 = \sum_{i=0}^m w_i \left( f(x_i; \alpha_0, \alpha_1, \dots, \alpha_n) - y_i \right)^2$$

dove  $w_i > 0$  sono numeri scelti come “pesi” delle osservazioni.

Una possibile scelta dei pesi è  $w_i = 1/e_i^2$ , dove  $e_i$  è una stima approssimata dell'errore sul dato  $i$ -esimo.

Si fa l'ipotesi che  $x_i$  non siano affetti da errore. In questo caso i moduli dei residui,  $|\varepsilon_i|$ , misurano la “distanza verticale” tra  $(x_i, y_i)$  e  $(x_i, f(x_i; \alpha_0, \alpha_1, \dots, \alpha_n))$ .

## Approssimazione lineare

Se  $f(x)$  è combinazione lineare di  $n + 1$  funzioni elementari  $\varphi_0(x), \varphi_1(x), \dots, \varphi_n(x)$  (che si assume siano continue e derivabili, con derivata continua in  $[a, b]$ , ossia siano sufficientemente regolari), allora

$$f(x) = \alpha_0 \varphi_0(x) + \dots + \alpha_n \varphi_n(x) = \sum_{j=0}^n \alpha_j \varphi_j(x) \quad \left( \text{per es. } \varphi_j(x) = x^j \right)$$

e il problema di approssimazione è lineare. Si tratta di trovare  $\alpha_0, \dots, \alpha_n$  tali che la funzione  $Q(\alpha_0, \dots, \alpha_n)$  sia minima:

$$Q(\alpha_0, \dots, \alpha_n) = \sum_{i=0}^m w_i \left( \sum_{j=0}^n \alpha_j \varphi_j(x_i) - y_i \right)^2$$

Se si indica con  $\mathbf{y} = (y_0, \dots, y_m)^T \in \mathbb{R}^{m+1}$  il vettore dei dati, con  $\boldsymbol{\alpha} = (\alpha_0, \alpha_1, \dots, \alpha_n)^T \in \mathbb{R}^{n+1}$  il vettore dei parametri da determinare, con  $A = (a_{ij})$  la matrice di  $m + 1$  righe e  $n + 1$  colonne, detta matrice di regressione lineare, così definita

$$A = \begin{pmatrix} \varphi_0(x_0) & \varphi_1(x_0) & \dots & \varphi_n(x_0) \\ \varphi_0(x_1) & \varphi_1(x_1) & \dots & \varphi_n(x_1) \\ \vdots & \vdots & \ddots & \vdots \\ \varphi_0(x_m) & \varphi_1(x_m) & \dots & \varphi_n(x_m) \end{pmatrix}$$

e con  $D = \text{diag}(\sqrt{w_i})_{i=0,\dots,m}$ , allora il vettore degli errori è definito come

$$\boldsymbol{\varepsilon} = D(A\boldsymbol{\alpha} - \mathbf{y})$$

e dunque la funzione  $Q(\alpha_0, \dots, \alpha_n)$ , che rappresenta la sua norma euclidea al quadrato, si può scrivere anche come

$$\begin{aligned} Q(\alpha_0, \dots, \alpha_n) &= \|D(A\boldsymbol{\alpha} - \mathbf{y})\|_2^2 \\ &= \left(D(A\boldsymbol{\alpha} - \mathbf{y})\right)^T \left(D(A\boldsymbol{\alpha} - \mathbf{y})\right) \\ &= \boldsymbol{\alpha}^T A^T D^2 A \boldsymbol{\alpha} - 2\mathbf{y}^T D^2 A \boldsymbol{\alpha} + \mathbf{y}^T D^2 \mathbf{y} \end{aligned}$$

La funzione  $\boldsymbol{\alpha}^T A^T D^2 A \boldsymbol{\alpha} - 2\boldsymbol{\alpha}^T D^2 \mathbf{y} + \mathbf{y}^T D^2 \mathbf{y}$  è una **forma quadratica** associata alla matrice  $A^T D^2 A$ .

## Esempio

Determinare i parametri  $\alpha_0$  e  $\alpha_1$  del modello  $f(x) = \alpha_0 \log(x) + \alpha_1$ , considerando come dati  $(0.5, 5)$ ,  $(1, 5)$ ,  $(4, 1)$  e  $(7, 0.1)$ .

Si assume che i primi due dati abbiano un errore pari a 0.1 mentre gli ultimi due abbiano errore superiore e pari a 0.5.

In questo caso  $m + 1 = 4$  ed  $n + 1 = 2$  (dunque  $m = 3$  ed  $n = 1$ ). Infatti occorre calcolare i due parametri  $\alpha_0$  e  $\alpha_1$  in modo che siano minimi possibile gli errori dati dalle 4 espressioni:

$$\alpha_0 \log(0.5) + \alpha_1 - 5 = \varepsilon_0$$

$$\alpha_0 \log(1) + \alpha_1 - 5 = \varepsilon_1$$

$$\alpha_0 \log(4) + \alpha_1 - 1 = \varepsilon_2$$

$$\alpha_0 \log(7) + \alpha_1 - 0.1 = \varepsilon_3$$

## Esempio

Usando il criterio dei minimi quadrati, occorre trovare  $\alpha_0$  e  $\alpha_1$  in modo che la **norma euclidea pesata** del vettore degli errori sia minima possibile:

$$Q(\alpha_0, \alpha_1) = \frac{1}{0.1^2} (\alpha_0 \log(0.5) + \alpha_1 - 5)^2 + \frac{1}{0.1^2} (\alpha_0 \log(1) + \alpha_1 - 5)^2 \\ + \frac{1}{0.5^2} (\alpha_0 \log(4) + \alpha_1 - 1)^2 + \frac{1}{0.5^2} (\alpha_0 \log(7) + \alpha_1 - 0.1)^2$$

Si osserva che la funzione si può esprimere anche nel seguente modo:

$$Q(\alpha_0, \alpha_1) = \left\| \begin{pmatrix} \frac{1}{0.1} (\alpha_0 \log(0.5) + \alpha_1 - 5) \\ \frac{1}{0.1} (\alpha_0 \log(1) + \alpha_1 - 5) \\ \frac{1}{0.5} (\alpha_0 \log(4) + \alpha_1 - 1) \\ \frac{1}{0.5} (\alpha_0 \log(7) + \alpha_1 - 0.1) \end{pmatrix} \right\|^2 \\ = \left\| \begin{pmatrix} \frac{1}{0.1} & 0 & 0 & 0 \\ 0 & \frac{1}{0.1} & 0 & 0 \\ 0 & 0 & \frac{1}{0.5} & 0 \\ 0 & 0 & 0 & \frac{1}{0.5} \end{pmatrix} \begin{pmatrix} \log(0.5) & 1 \\ \log(1) & 1 \\ \log(4) & 1 \\ \log(7) & 1 \end{pmatrix} \begin{pmatrix} \alpha_0 \\ \alpha_1 \end{pmatrix} - \begin{pmatrix} 5 \\ 5 \\ 1 \\ 0.1 \end{pmatrix} \right\|^2$$

## Esempio

Ponendo

$$D = \begin{pmatrix} \frac{1}{0.1} & 0 & 0 & 0 \\ 0 & \frac{1}{0.1} & 0 & 0 \\ 0 & 0 & \frac{1}{0.5} & 0 \\ 0 & 0 & 0 & \frac{1}{0.5} \end{pmatrix}; A = \begin{pmatrix} \log(0.5) & 1 \\ \log(1) & 1 \\ \log(4) & 1 \\ \log(7) & 1 \end{pmatrix}; \alpha = \begin{pmatrix} \alpha_0 \\ \alpha_1 \end{pmatrix}; \mathbf{y} = \begin{pmatrix} 5 \\ 5 \\ 1 \\ 0.1 \end{pmatrix}$$

la funzione da minimizzare rispetto ai parametri si scrive come

$$Q(\alpha_0, \alpha_1) = \|D(A\alpha - \mathbf{y})\|^2 = (D(A\alpha - \mathbf{y}))^T (D(A\alpha - \mathbf{y})) = (A\alpha - \mathbf{y})^T D^2 (A\alpha - \mathbf{y})$$

Si può anche porre  $\tilde{A} = DA = \begin{pmatrix} \frac{\log(0.5)}{0.1} & \frac{1}{0.1} \\ \frac{\log(1)}{0.1} & \frac{1}{0.1} \\ \frac{\log(4)}{0.5} & \frac{1}{0.5} \\ \frac{\log(7)}{0.5} & \frac{1}{0.5} \end{pmatrix}$  e  $\tilde{\mathbf{y}} = D\mathbf{y} = \begin{pmatrix} \frac{5}{0.1} \\ \frac{5}{0.1} \\ \frac{1}{0.5} \\ \frac{0.1}{0.5} \end{pmatrix}$ , da cui

$$Q(\alpha_0, \alpha_1) = \|\tilde{A}\alpha - \tilde{\mathbf{y}}\|^2 = (\tilde{A}\alpha - \tilde{\mathbf{y}})^T (\tilde{A}\alpha - \tilde{\mathbf{y}})$$

Il problema si riformula come il problema di trovare la soluzione di

$$\min_{\alpha \in \mathbb{R}^{n+1}} \|DA\alpha - D\mathbf{y}\|_2^2 = \min_{\alpha \in \mathbb{R}^{n+1}} \|\tilde{A}\alpha - \tilde{\mathbf{y}}\|^2$$

dove  $\tilde{A} = DA$  e  $\tilde{\mathbf{y}} = D\mathbf{y}$ .

Condizione necessaria perchè  $\alpha^* = (\alpha_0^*, \dots, \alpha_n^*)^T$  renda minima  $Q(\alpha_0, \dots, \alpha_n)$  è che il gradiente di  $Q(\alpha_0, \dots, \alpha_n)$  sia nullo per  $\alpha = \alpha^*$ .

## Formulazione del problema

Si deriva allora la funzione  $\sum_{i=0}^m w_i (\sum_{j=0}^n \varphi_j(x_i) \alpha_j - y_i)^2$  rispetto alle variabili  $\alpha_j$ ,  $j = 0, \dots, m$ , e si pone ciascuna derivata uguale a zero:

$$\begin{aligned} \frac{\partial}{\partial \alpha_k} \left( \sum_{i=0}^m w_i \left( \sum_{j=0}^n \varphi_j(x_i) \alpha_j - y_i \right)^2 \right) &= 0 \\ 2 \sum_{i=0}^m w_i \left( \sum_{j=0}^n \varphi_j(x_i) \alpha_j - y_i \right) \varphi_k(x_i) &= 0 \\ \sum_{i=0}^m w_i \sum_{j=0}^n \varphi_j(x_i) \varphi_k(x_i) \alpha_j - \sum_{j=0}^m w_i y_i \varphi_k(x_i) &= 0 \\ \sum_{j=0}^n \alpha_j \sum_{i=0}^m w_i \varphi_j(x_i) \varphi_k(x_i) &= \sum_{i=0}^m w_i y_i \varphi_k(x_i) \quad k = 0, \dots, n \\ \begin{cases} \alpha_0 \sum_{i=0}^m w_i \varphi_0(x_i) \varphi_0(x_i) + \alpha_1 \sum_{i=0}^m w_i \varphi_0(x_i) \varphi_1(x_i) + \dots + \alpha_n \sum_{i=0}^m w_i \varphi_0(x_i) \varphi_n(x_i) = \sum_{i=0}^m w_i y_i \varphi_0(x_i) \\ \alpha_0 \sum_{i=0}^m w_i \varphi_1(x_i) \varphi_0(x_i) + \alpha_1 \sum_{i=0}^m w_i \varphi_1(x_i) \varphi_1(x_i) + \dots + \alpha_n \sum_{i=0}^m w_i \varphi_1(x_i) \varphi_n(x_i) = \sum_{i=0}^m w_i y_i \varphi_1(x_i) \\ \vdots \\ \alpha_0 \sum_{i=0}^m w_i \varphi_n(x_i) \varphi_0(x_i) + \alpha_1 \sum_{i=0}^m w_i \varphi_n(x_i) \varphi_1(x_i) + \dots + \alpha_n \sum_{i=0}^m w_i \varphi_n(x_i) \varphi_n(x_i) = \sum_{i=0}^m w_i y_i \varphi_n(x_i) \end{cases} \end{aligned}$$

## Formulazione del problema

dove la matrice del sistema  $B \in \mathbb{R}^{(n+1) \times (n+1)}$  ha componenti  $b_{jk} = \sum_{i=0}^m w_i \varphi_j(x_i) \varphi_k(x_i)$  e il termine noto ha componenti  $d_j = \sum_{i=0}^m w_i y_i \varphi_j(x_i)$ .

$$B = \begin{pmatrix} \sum_{i=0}^m w_i \varphi_0(x_i) \varphi_0(x_i) & \sum_{i=0}^m w_i \varphi_0(x_i) \varphi_1(x_i) & \dots & \sum_{i=0}^m w_i \varphi_0(x_i) \varphi_n(x_i) \\ \sum_{i=0}^m w_i \varphi_1(x_i) \varphi_0(x_i) & \sum_{i=0}^m w_i \varphi_1(x_i) \varphi_1(x_i) & \dots & \sum_{i=0}^m w_i \varphi_1(x_i) \varphi_n(x_i) \\ \vdots & \vdots & \ddots & \vdots \\ \sum_{i=0}^m w_i \varphi_n(x_i) \varphi_0(x_i) & \sum_{i=0}^m w_i \varphi_n(x_i) \varphi_1(x_i) & \dots & \sum_{i=0}^m w_i \varphi_n(x_i) \varphi_n(x_i) \end{pmatrix} \quad \mathbf{d} = \begin{pmatrix} \sum_{i=0}^m w_i y_i \varphi_0(x_i) \\ \sum_{i=0}^m w_i y_i \varphi_1(x_i) \\ \vdots \\ \sum_{i=0}^m w_i y_i \varphi_n(x_i) \end{pmatrix}$$

Si può osservare che  $B = A^T D^2 A$  e  $\mathbf{d} = A^T D^2 \mathbf{y}$ .

$$A = \begin{pmatrix} \varphi_0(x_0) & \varphi_1(x_0) & \dots & \varphi_n(x_0) \\ \varphi_0(x_1) & \varphi_1(x_1) & \dots & \varphi_n(x_1) \\ \vdots & \vdots & \ddots & \vdots \\ \varphi_0(x_m) & \varphi_1(x_m) & \dots & \varphi_n(x_m) \end{pmatrix}$$

Pertanto il sistema delle **equazioni normali** è

$$A^T D^2 A \alpha = A^T D^2 \mathbf{y} \quad \tilde{A}^T \tilde{A} \alpha = \tilde{A}^T \tilde{\mathbf{y}}$$

o, se  $D = I_{m+1}$ ,

$$A^T A \alpha = A^T \mathbf{y}.$$

## Formulazione del problema

Il sistema di equazioni normali è un sistema di  $n + 1$  equazioni in  $n + 1$  incognite, con  $B$  semidefinita positiva (forma quadratica semidefinita positiva).

Pertanto se  $\alpha^*$  è punto di minimo, ossia soluzione di

$$\min_{\alpha \in \mathbb{R}^{n+1}} \|\tilde{A}\alpha - \tilde{\mathbf{y}}\|_2^2 = \min_{\alpha \in \mathbb{R}^{n+1}} Q(\alpha_0, \dots, \alpha_n) \quad (1)$$

allora  $\alpha^*$  è soluzione di

$$\tilde{A}^T \tilde{A} \alpha = \tilde{A}^T \tilde{\mathbf{y}} \quad (2)$$

Viceversa si può mostrare che se  $\alpha^*$  è soluzione del sistema di equazioni normali, allora è punto di minimo, ossia è soluzione di (1).

## Formulazione del problema

Infatti, se  $\alpha^*$  è soluzione di (2),  $\tilde{A}^T \tilde{A} \alpha^* = \tilde{A}^T \tilde{y}$ , oppure  $\tilde{y}^T \tilde{A} = \alpha^{*T} \tilde{A}^T \tilde{A}$ , allora vale che

$$\begin{aligned} Q(\alpha) - Q(\alpha^*) &= \alpha^T \tilde{A}^T \tilde{A} \alpha - 2\tilde{y}^T \tilde{A} \alpha + \tilde{y}^T \tilde{y} - \alpha^{*T} \tilde{A}^T \tilde{A} \alpha^* + 2\tilde{y}^T \tilde{A} \alpha^* \\ &\quad - \tilde{y}^T \tilde{y} \\ &= \alpha^T \tilde{A}^T \tilde{A} \alpha - \alpha^{*T} \tilde{A}^T \tilde{A} \alpha^* + 2\tilde{y}^T \tilde{A} (\alpha^* - \alpha) \\ &= \alpha^T \tilde{A}^T \tilde{A} \alpha - \alpha^{*T} \tilde{A}^T \tilde{A} \alpha^* + 2\alpha^{*T} \tilde{A}^T \tilde{A} (\alpha^* - \alpha) \\ &= \alpha^T \tilde{A}^T \tilde{A} \alpha + \alpha^{*T} \tilde{A}^T \tilde{A} \alpha^* - 2\alpha^{*T} \tilde{A}^T \tilde{A} \alpha \\ &= (\alpha - \alpha^*)^T \tilde{A}^T \tilde{A} (\alpha - \alpha^*) \geq 0 \end{aligned}$$

Per cui  $Q(\alpha) \geq Q(\alpha^*)$ . Dunque  $\alpha^*$  è punto di minimo. Se  $\tilde{A}^T \tilde{A}$  è definita positiva, allora  $\alpha^*$  è punto di minimo proprio ( $Q(\alpha) > Q(\alpha^*)$  per  $\alpha \neq \alpha^*$ ). Pertanto i due problemi (1) e (2) sono equivalenti.

In sintesi, abbiamo dimostrato che [la soluzione del problema di miglior approssimazione lineare secondo il criterio dei minimi quadrati si trova studiando le soluzioni del sistema](#)

$$\tilde{A}^T \tilde{A} \alpha = \tilde{A}^T \tilde{y}$$

## Formulazione del problema

Vale che

$$0 = \tilde{A}^T \tilde{y} - \tilde{A}^T \tilde{A} \alpha = \tilde{A}^T (\tilde{y} - \tilde{A} \alpha) = \tilde{A}^T r$$

Nell'esempio, si tratta di risolvere il sistema

$$\tilde{A}^T \tilde{A} \alpha = \tilde{A}^T \tilde{y}$$

Da cui si ottiene  $\alpha_0 = -1.2525$  e  $\alpha_1 = 4.4917$ .

$$\min_{\alpha \in \mathbb{R}^{n+1}} \|A\alpha - \mathbf{y}\|_2^2 \quad A \in \mathbb{R}^{(m+1) \times (n+1)}, \quad \mathbf{y} \in \mathbb{R}^{m+1}$$

Sia  $S(A)$  il sottospazio di  $\mathbb{R}^{m+1}$  generato dalle colonne della matrice  $A$ .

- Se  $\mathbf{y} \in S(A)$ , allora si tratta di trovare le coordinate di  $\mathbf{y}$  rispetto all'insieme di generatori rappresentato dalle colonne della matrice  $A$  (il problema diventa di interpolazione, poiché  $\min \|A\alpha - \mathbf{y}\|_2^2 = 0$ ).
- Se  $\mathbf{y} \notin S(A)$ , si tratta di determinare  $\hat{\mathbf{y}} \in S(A)$  tale che  $\|\mathbf{y} - \hat{\mathbf{y}}\|_2^2$  è minimo. Tale  $\hat{\mathbf{y}}$  è la proiezione ortogonale di  $\mathbf{y}$  su  $S(A)$  ed è univocamente determinato.  $\mathbf{r} = \mathbf{y} - \hat{\mathbf{y}}$  è un vettore ortogonale a  $S(A)$ , ossia  $\mathbf{r} \perp$  a tutte le colonne di  $A$ ,  $A^T \mathbf{r} = \mathbf{0}$ . Ogni altro  $\mathbf{y}^* \in S(A)$  è tale che

$$\begin{aligned} \|\mathbf{y} - \mathbf{y}^*\|^2 &= \|\mathbf{y} - \hat{\mathbf{y}} + \hat{\mathbf{y}} - \mathbf{y}^*\|_2^2 = (\mathbf{y} - \hat{\mathbf{y}} + \hat{\mathbf{y}} - \mathbf{y}^*)^T (\mathbf{y} - \hat{\mathbf{y}} + \hat{\mathbf{y}} - \mathbf{y}^*) \\ &= (\mathbf{y} - \hat{\mathbf{y}})^T (\mathbf{y} - \hat{\mathbf{y}}) + (\hat{\mathbf{y}} - \mathbf{y}^*)^T (\hat{\mathbf{y}} - \mathbf{y}^*) + 2 \underbrace{(\hat{\mathbf{y}} - \mathbf{y}^*)^T}_{\in S(A), \text{ se } \hat{\mathbf{y}} \neq \mathbf{y}^*} \underbrace{(\mathbf{y} - \hat{\mathbf{y}})}_{= \mathbf{r}} \\ &= \|\mathbf{y} - \hat{\mathbf{y}}\|_2^2 + \|\hat{\mathbf{y}} - \mathbf{y}^*\|_2^2 > \|\mathbf{y} - \hat{\mathbf{y}}\|_2^2 \end{aligned}$$

## Interpretazione geometrica


Poiché  $A^T \mathbf{r} = \mathbf{0}$ ,  $A^T (\mathbf{y} - \hat{\mathbf{y}}) = \mathbf{0}$ ,  $A^T \mathbf{y} = A^T \hat{\mathbf{y}}$

$$\hat{\mathbf{y}} \in S(A) \implies \exists \alpha^* \text{ tale che } \hat{\mathbf{y}} = A\alpha^* \implies A^T \mathbf{y} = A^T A\alpha^*$$

e  $\alpha^*$  è la soluzione del problema.

Se le colonne di  $A$  sono linearmente indipendenti allora  $\alpha^*$  è unica.

Se le colonne di  $A$  sono linearmente dipendenti e  $\text{rank}(A) = k$ , esistono  $\infty^{n+1-k}$  vettori  $\alpha^*$  tali che  $A\alpha^* = \hat{\mathbf{y}}$ . Tra queste infinite soluzioni si considera quella di norma euclidea minima.





L'approssimazione lineare secondo il criterio dei minimi quadrati ha una e una sola soluzione  $\iff A$  è di rango pieno  $\iff$  i vettori  $\begin{pmatrix} \varphi_j(x_0) \\ \vdots \\ \varphi_j(x_m) \end{pmatrix}$  sono linearmente indipendenti. In tal caso la soluzione vale

$$\alpha^* = (A^T A)^{-1} A^T y = A^+ y$$

Questo accade se  $\varphi_0, \dots, \varphi_n$  sono funzioni linearmente indipendenti sui punti distinti  $x_0, \dots, x_m$ .

L'approssimazione lineare secondo il criterio dei minimi quadrati allora ha una sola soluzione comunque siano scelti i punti  $x_0, \dots, x_m$  purchè distinti in  $[a, b]$  se le funzioni  $\varphi_0, \dots, \varphi_n$  formano una matrice a colonne linearmente indipendenti.

## Approssimazione polinomiale

Se  $\varphi_j(x) = x^j$ , ossia nel caso di approssimazione polinomiale,  $x^0 = 1, x, \dots, x^n$  sono sempre linearmente indipendenti su  $m + 1 \geq n + 1$  punti comunque scelti in  $[a, b]$  purchè **distinti**.

L'approssimazione lineare polinomiale ha sempre una e una sola soluzione.

Se  $m = n$ , la soluzione è il polinomio di interpolazione di grado  $n$  relativo a  $x_0, \dots, x_n$ .

Se  $m > n$ , la soluzione è il polinomio di grado  $n$  con coefficienti che sono soluzione di

$$A^T D^2 A \alpha = A^T D^2 y \quad \text{o, equivalentemente,} \quad B \alpha = d$$

dove

$$A^T D^2 A = \begin{pmatrix} \sum_{i=0}^m w_i & \sum_{i=0}^m w_i x_i & \dots & \sum_{i=0}^m w_i x_i^n \\ \sum_{i=0}^m w_i x_i & \sum_{i=0}^m w_i x_i^2 & \dots & \sum_{i=0}^m w_i x_i^{n+1} \\ \vdots & \vdots & \ddots & \vdots \\ \sum_{i=0}^m w_i x_i^n & \sum_{i=0}^m w_i x_i^{n+1} & \dots & \sum_{i=0}^m w_i x_i^{2n} \end{pmatrix}, \quad A^T D^2 y = \begin{pmatrix} \sum_{i=0}^m w_i y_i \\ \sum_{i=0}^m w_i y_i x_i \\ \vdots \\ \sum_{i=0}^m w_i y_i x_i^n \end{pmatrix}$$

o, equivalentemente,

$$b_{jk} = \sum_{i=0}^m w_i x_i^{j+k-2}, \quad d_j = \sum_{i=0}^m w_i y_i x_i^{j-1} \quad j, k = 1, \dots, n+1.$$

**N.B.** Si ricorda che la numerazione di righe e colonne di matrici e vettori inizia da 1, mentre le numerazioni dei punti  $x_i$  e delle funzioni  $\varphi_j(x)$  iniziano entrambe da zero.

La matrice di regressione lineare risulta infatti

$$A = \begin{pmatrix} 1 & x_0 & \dots & x_0^n \\ 1 & x_1 & \dots & x_1^n \\ \vdots & \vdots & & \vdots \\ 1 & x_m & \dots & x_m^n \end{pmatrix} \in \mathbb{R}^{(m+1) \times (n+1)}$$

## Esempi

- $n = 0$ .  $f(x) = \alpha_0$ .

$$A = \begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix} \Rightarrow A^T D^2 A = \sum_{i=0}^m w_i, \quad A^T D^2 \mathbf{y} = \sum_{i=0}^m w_i y_i \Rightarrow \alpha_0 = \frac{\sum_{i=0}^m w_i y_i}{\sum_{i=0}^m w_i}$$

$\alpha_0$  è il **baricentro dei dati**.

- $n = 1$ .  $f(x) = \alpha_0 + \alpha_1 x$ . Questo è il caso che permette di costruire la **retta di regressione**:

$$A = \begin{pmatrix} 1 & x_0 \\ 1 & x_1 \\ \vdots & \vdots \\ 1 & x_m \end{pmatrix} \Rightarrow A^T D^2 A = \begin{pmatrix} \sum_{i=0}^m w_i & \sum_{i=0}^m w_i x_i \\ \sum_{i=0}^m w_i x_i & \sum_{i=0}^m w_i x_i^2 \end{pmatrix}, \quad A^T D^2 \mathbf{y} = \begin{pmatrix} \sum_{i=0}^m w_i y_i \\ \sum_{i=0}^m w_i y_i x_i \end{pmatrix}$$

Se  $D^2 = I_{m+1}$ , allora

$$A^T A = \begin{pmatrix} m+1 & \sum_{i=0}^m x_i \\ \sum_{i=0}^m x_i & \sum_{i=0}^m x_i^2 \end{pmatrix}, \quad A^T \mathbf{y} = \begin{pmatrix} \sum_{i=0}^m y_i \\ \sum_{i=0}^m y_i x_i \end{pmatrix}$$

$$\alpha_0 = \frac{(\sum x_i^2)(\sum y_i) - (\sum x_i)(\sum x_i y_i)}{(m+1)(\sum x_i^2) - (\sum x_i)^2}, \quad \alpha_1 = \frac{(m+1)(\sum x_i y_i) - (\sum x_i)(\sum y_i)}{(m+1)(\sum x_i^2) - (\sum x_i)^2}.$$

## Risoluzione di $A^T A \alpha = A^T y$ con $\text{rank}(A) = n$

Poichè  $A^T A$  è simmetrica definita positiva, un modo naturale per risolvere il sistema delle equazioni normali è usare la fattorizzazione di Cholesky:

- calcolo di  $B = A^T A$  e  $d = A^T y$ ;
- fattorizzazione di  $B = LL^T$ ;
- risoluzione dei sistemi  $Lz = d$  e  $L^T \alpha = z$ .

Il costo è di  $mn^2/2 + n^3/6 + n^2$  prodotti e altrettante somme. Dal teorema di condizionamento dei sistemi lineari, per la soluzione calcolata  $\tilde{\alpha}$  si ha:

$$\frac{\|\Delta \tilde{\alpha}\|_2}{\|\tilde{\alpha}\|_2} \leq \frac{\mu_2(B)}{1 - \mu_2(B) \frac{\|\Delta B\|_2}{\|B\|_2}} \left( \frac{\|\Delta B\|_2}{\|B\|_2} + \frac{\|\Delta d\|_2}{\|d\|_2} \right)$$

Di più, rispetto alle perturbazioni  $\Delta A$  sui valori iniziali di  $A$ , assunto che  $\eta = \|\Delta A\|_2 / \|A\|_2$  sia piccolo, si ha:

$$\frac{\|\Delta \tilde{\alpha}\|}{\|\tilde{\alpha}\|} \leq \eta \left( \mu_2(A) + \mu_2^2(A) \tan(\theta) \right) + \mathcal{O}(\eta^2) \quad \text{e} \quad \frac{\|\Delta r\|}{\|y\|} \leq 2\eta \mu_2(A) + \mathcal{O}(\eta^2)$$

dove  $\theta$  è tale che  $\sin(\theta) = \|r\|_2 / \|y\|_2$ , essendo  $r = y - A\tilde{\alpha}$  il residuo. Infine, vale che

$$\mu_2(A^T A) = \frac{\lambda_{\max}(A^T A)}{\lambda_{\min}(A^T A)} = (\mu_2(A))^2$$

## Risoluzione di $A^T A \alpha = A^T y$ con $\text{rank}(A) = n$

Se  $A$  è a colonne **quasi linearmente dipendenti**,  $\mu_2(A)$  è grande e  $\mu_2(A^T A)$ , essendo il suo quadrato, è un grosso amplificatore degli errori sui dati, che sono affetti da errore in quanto provengono da calcoli precedenti. Se poi  $A$  è mal condizionata, il calcolo di  $A^T A$  può portare a grossi inconvenienti:

$$A = \begin{pmatrix} 1 & 1 \\ \varepsilon & 0 \\ 0 & \varepsilon \end{pmatrix} \Rightarrow A^T A = \begin{pmatrix} 1 + \varepsilon^2 & 1 \\ 1 & 1 + \varepsilon^2 \end{pmatrix} \approx \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}$$

che è singolare se  $\varepsilon^2$  è minore della precisione di macchina.

## Risoluzione numerica del problema dei minimi quadrati

Un **metodo più stabile** per il calcolo della soluzione di  $A^T A \alpha = A^T \mathbf{y}$  è basato sulla decomposizione  $QR$  della matrice  $A$  mediante trasformazioni elementari ortogonali:

$$A = Q\bar{R} = Q \begin{pmatrix} R \\ \mathbf{0} \end{pmatrix} \Leftrightarrow Q^T A = \begin{pmatrix} R \\ \mathbf{0} \end{pmatrix}$$

con  $\bar{R}$  matrice  $(m+1) \times (n+1)$ ,  $R$  triangolare superiore di ordine  $n+1$  e  $Q$  ortogonale di ordine  $m+1$ . Ricordiamo che si deve risolvere

$$\min_{\alpha} \|A\alpha - \mathbf{y}\|_2^2$$

Poiché le trasformazioni ortogonali non alterano la norma euclidea ( $\|\mathbf{z}\|_2 = \|U\mathbf{z}\|_2$  per ogni  $\mathbf{z} \in \mathbb{R}^{m+1}$  e  $U$  ortogonale), segue che

$$\|A\alpha - \mathbf{y}\|_2^2 = \|Q^T(A\alpha - \mathbf{y})\|_2^2 = \|Q^T A\alpha - Q^T \mathbf{y}\|_2^2 = \left\| \begin{pmatrix} R \\ \mathbf{0} \end{pmatrix} \alpha - \begin{pmatrix} \tilde{\mathbf{y}}_1 \\ \tilde{\mathbf{y}}_2 \end{pmatrix} \right\|_2^2$$

dove si è posto  $Q^T \mathbf{y} = \begin{pmatrix} \tilde{\mathbf{y}}_1 \\ \tilde{\mathbf{y}}_2 \end{pmatrix} \begin{matrix} n+1 \text{ componenti} \\ m-n \text{ componenti} \end{matrix}$ .

## Risoluzione numerica del problema dei minimi quadrati

Allora

$$\|A\alpha - \mathbf{y}\|_2^2 = \left\| \begin{pmatrix} R\alpha - \tilde{\mathbf{y}}_1 \\ -\tilde{\mathbf{y}}_2 \end{pmatrix} \right\|_2^2 = \|R\alpha - \tilde{\mathbf{y}}_1\|_2^2 + \|\tilde{\mathbf{y}}_2\|_2^2 \geq \|\tilde{\mathbf{y}}_2\|_2^2$$

dove il segno di uguaglianza vale se e solo se  $R\alpha = \tilde{\mathbf{y}}_1$ .

Il valore minimo possibile vale  $\|\tilde{\mathbf{y}}_2\|_2^2$  (somma dei quadrati dei residui).

Allora la soluzione del problema si ottiene come soluzione del sistema

$$R\alpha = \tilde{\mathbf{y}}_1$$

e deve essere  $\alpha^* = R^{-1} \tilde{\mathbf{y}}_1$ .

La somma dei quadrati dei residui vale  $\sum_{i=n+1}^m (\tilde{y}_2^{(i)})^2$  e il residuo  $\mathbf{r} = \mathbf{y} - A\alpha$  è tale che

$$\|Q^T(A\alpha^* - \mathbf{y})\|_2^2 = \left\| \begin{pmatrix} \mathbf{0} \\ -\tilde{\mathbf{y}}_2 \end{pmatrix} \right\|_2^2 \Rightarrow Q^T \mathbf{r} = \begin{pmatrix} \mathbf{0} \\ \tilde{\mathbf{y}}_2 \end{pmatrix}$$

e pertanto

$$\mathbf{r} = Q \begin{pmatrix} \mathbf{0} \\ \tilde{\mathbf{y}}_2 \end{pmatrix}.$$

In tal caso il numero di condizione del problema coincide con il numero di condizione di  $R$ :

$$\mu_2(R) = \sqrt{\frac{\lambda_{\max}(R^T R)}{\lambda_{\min}(R^T R)}}$$

Poiché

$$R^T R = (R^T \ 0) \begin{pmatrix} R \\ \mathbf{0} \end{pmatrix} = A^T Q Q^T A = A^T A$$

segue che

$$\mu_2(R) = \sqrt{\frac{\lambda_{\max}(A^T A)}{\lambda_{\min}(A^T A)}} = \mu_2(A).$$

## Codice Matlab

```
function [alpha, res, r] = regressLineare(A, y)
%regressLineare - Problema lineare di regressione polinomiale
% INPUT
% A (double, array) - Matrice di regressione lineare
% y (double, array) - Vettore delle osservazioni
% OUTPUT
% alpha (double, array) - Vettore soluzione
% res (double) - Norma 2 del vettore residuo
% r (double, array) - Vettore residuo
[m, n] = size(A);
[Q, R] = qr(A);
ytilde = Q' * y;
alpha = R(1:n, 1:n) \ ytilde(1:n);
r = Q * [zeros(n,1); ytilde(n+1 : m)]; % residuo: r = y - A*alpha
res = norm(r,2)^2; % res = norm(ytilde(n+1:m),2)^2;
end
```

L'approssimazione polinomiale mediante un polinomio di grado  $n$  relativa a  $m$  coppie di dati  $(x, y)$  ( $m \geq n + 1$ ) si ottiene con

```
>> p = polyfit(x, y, n);
>> z = polyval(p, punti);
```

Se  $m = n + 1$  si ottiene interpolazione polinomiale.